

SSC0158 – Arquiteturas RESTful e Boas Práticas de API

Grupo 4

Márcio Guilherme Vieira Silva – 11355786

Rafael Jun Morita – 10845040

Thiago Prado Dalla Dea – 12691710

Abstract—Este relatório apresenta um estudo empírico sobre o impacto de decisões de design em APIs RESTful no desempenho, na observabilidade e na evolutividade de aplicações distribuídas. O trabalho concentra-se em duas decisões recorrentes no desenvolvimento de APIs: o mecanismo de paginação, comparando as abordagens *Offset* e *Cursor*, e a estratégia de versionamento, comparando o versionamento via URI e via cabeçalhos HTTP por negociação de conteúdo. Foi implementado um protótipo funcional com FastAPI, SQLite, Docker Compose, Prometheus, Grafana, dashboard web e scripts de geração de dados e teste de carga. A API expõe rotas equivalentes para as estratégias avaliadas, permitindo a execução de experimentos controlados. Neste ciclo experimental, foram executadas 15.600 requisições HTTP em 60 execuções agregadas, com três níveis de carga, quatro alvos e cinco repetições por combinação. Os resultados incluem média, desvio padrão, intervalo de confiança de 95%, p95, *throughput* e taxa de erro.

Index Terms—REST, API, paginação, versionamento, FastAPI, Docker, Prometheus, Grafana, teste de carga.

I. INTRODUÇÃO

A arquitetura REST (*Representational State Transfer*) consolidou-se como uma das principais abordagens para construção de APIs web por combinar simplicidade, uso direto do protocolo HTTP e boa adequação a sistemas distribuídos [1]. Em aplicações em nuvem, APIs RESTful frequentemente atuam como camada de comunicação entre serviços, clientes, bancos de dados e mecanismos de observabilidade. Nesse contexto, decisões aparentemente locais de projeto, como paginação de coleções ou versionamento de representações, podem influenciar desempenho, confiabilidade, manutenibilidade e evolução do sistema.

Embora REST estabeleça restrições arquiteturais gerais, a implementação concreta de uma API envolve escolhas práticas que não são completamente determinadas pelo estilo arquitetural. Entre essas escolhas, destacam-se a forma de recuperar grandes coleções de dados e a forma de evoluir representações sem quebrar clientes existentes. A paginação baseada em *Offset* é simples e comum, mas pode degradar em páginas profundas porque a consulta precisa ignorar registros anteriores. Já a paginação baseada em *Cursor* tende a ser mais estável para percursos progressivos, pois usa um marcador para continuar a consulta. No versionamento, o uso de URIs versionadas, como `/v1/produtos`, é direto e explícito, enquanto a negociação por cabeçalhos preserva a URI do recurso e desloca a versão para a representação desejada.

Este trabalho avalia empiricamente essas decisões por meio de uma API *sandbox* de catálogo de produtos. O protótipo foi implementado em FastAPI, containerizado com Docker Compose e instrumentado para coleta de métricas em Prometheus. A execução experimental é apoiada por scripts de população de banco, testes de carga e visualização em dashboard web.

As principais contribuições do trabalho são:

- implementação de um protótipo RESTful containerizado para avaliação de decisões de design;
- comparação experimental entre paginação *Offset* e paginação *Cursor*;
- comparação experimental entre versionamento via URI e versionamento via cabeçalhos HTTP;
- instrumentação da API com métricas Prometheus e dashboard web simples;
- definição de protocolo experimental reproduzível para coleta de latência, *throughput*, erros e indicadores de evolutividade.

A. Definição do Problema

APIs RESTful são amplamente utilizadas em aplicações distribuídas, mas sua qualidade depende de decisões de design tomadas durante a implementação. Mecanismos de paginação e estratégias de versionamento influenciam tanto o comportamento em tempo de execução quanto a capacidade de evolução da API.

A pergunta de pesquisa principal é:

Como decisões de design em APIs RESTful, especificamente paginação *Offset* versus *Cursor* e versionamento via URI versus cabeçalhos HTTP, impactam o desempenho e a evolutividade de uma API em ambiente containerizado?

B. Perguntas de Pesquisa

A pergunta principal foi desdobrada nas seguintes perguntas de pesquisa:

- **RQ1:** Como a paginação baseada em *Offset* se compara à paginação baseada em *Cursor* em latência, *throughput*, p95 e taxa de erro sob diferentes níveis de carga?
- **RQ2:** O versionamento por cabeçalhos HTTP introduz custo mensurável de desempenho em relação ao versionamento via URI?
- **RQ3:** Quais *trade-offs* de evolutividade e observabilidade surgem entre versionamento explícito por URI e negociação de conteúdo por cabeçalhos HTTP?

C. Hipóteses

- **H1 (Desempenho/Paginação):** a paginação baseada em *Cursor* apresentará latência mais estável em consultas a páginas profundas quando comparada à paginação baseada em *Offset*.
- **H2 (Evolutividade/Versionamento):** o versionamento via cabeçalhos HTTP proporcionará menor acoplamento entre URI e versão da representação, facilitando a evolução da API em comparação ao versionamento explícito via URI.

II. TRABALHOS RELACIONADOS

O levantamento bibliográfico foi conduzido a partir de uma adaptação simplificada da metodologia PRISMA, denominada Micro-PRISMA. O objetivo foi identificar trabalhos sobre desenho, evolução, desempenho e avaliação de APIs RESTful.

A. Strings de Busca e Bases

Foram definidas as seguintes strings:

- "REST API" AND ("design" OR "anti-patterns") AND ("performance" OR "maintainability")
- "RESTful" AND "versioning" AND ("evolution" OR "maintainability")
- "REST API" AND "pagination" AND ("performance" OR "evaluation" OR "comparison")
- "RESTful API" AND "design rules" AND "empirical"

As bases consultadas foram IEEE Xplore, ACM Digital Library, Scopus e buscas complementares em arXiv/portais dos editores para validação de metadados bibliográficos. Na triagem, foram priorizados estudos com avaliação empírica, análise de APIs reais, comparação de desempenho ou discussão direta sobre evolução/versionamento.

B. Critérios de Seleção

- **Inclusão:** artigos entre 2018 e 2026; foco em APIs REST, design de APIs, evolução de APIs, desempenho sob carga ou observabilidade; disponibilidade de método, métricas ou ambiente experimental.
- **Exclusão:** tutoriais sem revisão técnica, textos puramente opinativos, trabalhos exclusivamente focados em segurança, estudos sem relação com APIs HTTP/REST ou sem contribuição metodológica para o projeto.

Foram identificados 45 registros iniciais. Após leitura de títulos e resumos, 12 trabalhos foram selecionados para leitura completa ou leitura técnica parcial. A Tabela I resume as 8 referências utilizadas diretamente na fundamentação do estudo, além da referência conceitual de Fielding usada para caracterizar o estilo REST.

C. Lacuna Identificada

A literatura revisada mostra que há muitos estudos sobre conformidade REST, regras de design, comparação entre

modelos de API e evolução de APIs em microsserviços. Entretanto, poucos trabalhos isolam experimentalmente decisões internas de uma API REST, como paginação *Offset* versus *Cursor* e versionamento por URI versus cabeçalhos, em um mesmo ambiente e com métricas objetivas de desempenho e evolutividade. Este trabalho busca preencher essa lacuna por meio de uma API controlada, na qual as estratégias são implementadas lado a lado e podem ser avaliadas sob os mesmos cenários de carga.

III. METODOLOGIA

A metodologia adotada combina implementação de protótipo funcional, geração controlada de dados, execução de testes de carga, coleta de métricas reais e análise quantitativa. O domínio escolhido é um catálogo de produtos, por ser simples de modelar, permitir grande volume de registros e representar uma operação comum em APIs reais: listagem paginada de recursos.

A. Visão Geral da Abordagem

O estudo foi conduzido em quatro etapas. Primeiro, foi implementada uma API RESTful *sandbox* com rotas equivalentes para as decisões de design avaliadas. Segundo, foi criada uma base de dados artificial e determinística com 10.000 produtos. Terceiro, foram executados cenários controlados de carga contra os endpoints de paginação e versionamento. Por fim, os resultados foram agregados em arquivos JSON, CSV, tabelas LaTeX e gráfico SVG.

A opção por uma API *sandbox* reduz interferências de regras de negócio externas e permite isolar o impacto das decisões avaliadas. Os dados de domínio são artificiais, mas os dados experimentais são reais: latências, *throughput*, erros, CPU e memória foram coletados durante a execução do protótipo.

B. Decisões de Design Avaliadas

1) *Paginação*: Foram avaliadas duas estratégias. A paginação *Offset* usa os parâmetros `limit` e `offset`, sendo simples de consumir e comum em APIs REST. A paginação *Cursor* usa um marcador de continuidade, neste caso o identificador do último produto retornado, evitando saltos baseados em deslocamento absoluto. O experimento utilizou página profunda para enfatizar o possível custo de *Offset*.

2) *Versionamento*: Foram avaliadas duas estratégias. O versionamento via URI usa caminhos explícitos, como `/v1/produtos` e `/v2/produtos`. O versionamento via cabeçalhos HTTP usa negociação de conteúdo, mantendo `/produtos` e selecionando a versão por `Accept: application/vnd.api.v2+json`. A versão v2 adiciona o campo `meta` com `timestamp`, representando uma evolução controlada da resposta.

C. Baselines e Estratégias Alternativas

- **Baseline de paginação:** paginação baseada em *Offset*, usando `limit` e `offset`.
- **Alternativa de paginação:** paginação baseada em *Cursor*, usando `cursor` como marcador do último identificador retornado.

TABLE I
EXTRAÇÃO DE DADOS DA LITERATURA SELECIONADA

Referência	Método	Métricas/Aspectos	Baseline/Comparação	Limitações para este trabalho
Elghazal et al. [2]	Teste de carga comparativo entre modelos de APIs em contexto de microsserviços.	Tempo de resposta, eficiência de transferência e taxa de erros.	REST vs. GraphQL.	Compara modelos de API, mas não isola decisões internas de paginação e versionamento REST.
Gholami et al. [3]	Proposta de <i>framework</i> para satisfazer requisitos de desempenho em sistemas containerizados.	Uso de recursos, tempo de resposta e atendimento de requisitos de desempenho.	Versão única ou configuração base vs. alternativas de adaptação/versionamento.	Não foca diretamente na comparação entre paginação <i>Offset</i> e <i>Cursor</i> .
Szewczyk e Skublewska-Paszkowska [4]	Benchmark quantitativo entre <i>frameworks</i> para implementação de APIs REST.	Tempo de resposta, consumo de memória e características de implantação.	Comparação entre <i>frameworks</i> REST em ambientes selecionados.	Avalia tecnologia de implementação, não decisões de modelagem de recursos.
Bogner et al. [5]	Análise de especificações OpenAPI para identificar violações de regras RESTful.	Precisão de detecção, regras violadas e tempo de análise.	APIs aderentes vs. APIs com violações de design.	Estudo estático; não mede impacto de violações sob carga.
Mabotha et al. [6]	Teste de desempenho de uma API dinâmica com FastAPI, Docker e Nginx.	Tempo de resposta, <i>throughput</i> e taxa de erros sob carga.	Avaliação de capacidade de uma arquitetura containerizada.	Não avalia variações de paginação ou versionamento como fatores experimentais.
Neumann et al. [7]	Análise empírica de APIs REST públicas.	Aderência a princípios REST, uso de verbos HTTP, URIs, códigos de status e documentação.	Padrões REST esperados vs. implementações reais.	Foca conformidade e design observado, sem experimentos de desempenho controlados.
De Luca et al. [8]	Estudo exploratório de <i>anti-patterns</i> arquiteturais em microsserviços acadêmicos.	Incidência de <i>anti-patterns</i> , impacto em escalabilidade e manutenibilidade.	Arquiteturas com e sem violações arquiteturais recorrentes.	Não quantifica isoladamente latência causada por decisões específicas de endpoints REST.
Kandiraju [9]	Proposta de APIs REST de <i>streaming</i> para exportação progressiva de dados relacionais.	Consumo de memória, latência de entrega e processamento incremental.	Exportação tradicional vs. recuperação progressiva por cursores.	Foca exportação de grandes volumes, não listagem paginada interativa de recursos.

- **Baseline de versionamento:** versionamento via URI, usando rotas `/v1/produtos` e `/v2/produtos`.
- **Alternativa de versionamento:** versionamento via cabeçalhos HTTP, usando `Accept: application/vnd.api.v1+json` ou `Accept: application/vnd.api.v2+json`.

D. Variáveis Independentes

As variáveis independentes são: estratégia de paginação, estratégia de versionamento, volume de dados, nível de carga concorrente e profundidade da página consultada.

E. Variáveis Dependentes

As variáveis dependentes são: latência média, p95, *throughput*, taxa de erros, uso de CPU, uso de memória e esforço de evolução. Para evolutividade, foram considerados acoplamento entre URI e versão, duplicação de rotas, compatibilidade com clientes existentes e clareza operacional.

F. Métricas

As métricas quantitativas utilizadas são:

- latência média, mínima, máxima, p90, p95 e p99;
- *throughput* em requisições por segundo;
- taxa de erro total e por código HTTP;
- uso médio e máximo de CPU do processo da API;
- memória residente média e máxima (RSS) do processo da API;

- média, desvio padrão e intervalo de confiança de 95% para as métricas repetidas;
- indicadores de evolutividade: rotas necessárias, acoplamento de URI e compatibilidade de versões.

G. Procedimento Experimental

O procedimento final foi automatizado pelo script `scripts/run_final_experiment.py`. O script recria a base experimental, popula 10.000 produtos, inicia a API FastAPI em porta local, monitora CPU e memória do processo via `/proc`, executa o benchmark controlado e encerra o serviço ao final.

Cada combinação de cenário e alvo foi executada cinco vezes. Em cada repetição, o benchmark disparou requisições concorrentes, registrando latência, status HTTP, quantidade de erros, tempo total e *throughput*. Os resultados foram exportados para `results/benchmark/raw.json`, `raw.csv`, `summary.json`, `summary.csv`, tabelas LaTeX e gráfico SVG.

H. Tratamento Estatístico

Para cada combinação de cenário e alvo, calculou-se a média das latências médias, o desvio padrão entre as cinco repetições e o intervalo de confiança de 95%. Como cada combinação possui cinco repetições, foi usado o valor crítico $t=2,776$ para quatro graus de liberdade. O p95 apresentado corresponde à média do p95 observado nas repetições.

I. Critérios de Aceitação das Hipóteses

A hipótese H1 é apoiada quando a paginação por *Cursor* apresenta menor latência média, p95 mais estável, maior ou igual *throughput* e taxa de erro não superior ao *Offset*, especialmente sob carga alta. A hipótese H2 é apoiada quando o versionamento por cabeçalhos preserva compatibilidade e reduz o acoplamento entre URI e versão sem introduzir custo relevante de desempenho.

IV. ARQUITETURA DO SISTEMA

A arquitetura implementada tem como objetivo permitir a avaliação controlada de decisões de design em APIs RESTful. O sistema é containerizável, expõe aplicação web simples, coleta métricas e registra resultados exportáveis. A Figura 1 resume os componentes.

A. Componentes

- **Protocolo de comunicação:** HTTP/REST, escolhido por aderência direta ao Tema 4 e aos objetivos de avaliar paginação, versionamento e boas práticas RESTful.
- **API intermediária:** aplicação FastAPI, responsável por expor endpoints REST, dashboard estático, *healthcheck* e métricas Prometheus.
- **Banco de dados:** SQLite armazenado em volume local. A escolha reduz dependências externas e concentra o experimento nas decisões de API.
- **Prometheus:** coleta métricas no endpoint `/metrics`, incluindo contadores por rota/status, histograma de duração e total de produtos.
- **Grafana:** serviço de visualização disponível na porta 3000.
- **Dashboard web:** página estática servida pela API para consultar produtos, alternar estratégia de paginação, alternar versionamento e visualizar respostas JSON.
- **Scripts experimentais:** scripts para popular banco, executar carga, monitorar CPU/memória e exportar resultados.

B. Broker e Delimitação da Trilha REST

O enunciado da disciplina menciona broker como componente recomendado para algumas trilhas. Neste projeto, a trilha é REST e a decisão arquitetural foi manter comunicação síncrona HTTP cliente-API, sem fila assíncrona intermediária, para não misturar o fator experimental com efeitos de mensageria. Essa ausência é uma delimitação técnica do Tema 4. O arquivo Mosquitto presente no repositório foi mantido apenas como artefato de configuração não utilizado, caso uma extensão futura queira transformar a coleta de métricas em eventos publicados por broker.

C. Justificativa Arquitetural

A separação entre API, banco, scripts de carga e observabilidade torna o sistema reprodutível e próximo de uma implantação em nuvem baseada em contêineres. FastAPI foi escolhido por facilitar a criação de endpoints REST e a execução com Uvicorn. SQLite foi escolhido por simplificar a execução e reduzir variabilidade externa; essa escolha é discutida como ameaça à validade externa.

V. IMPLEMENTAÇÃO

O protótipo foi implementado no repositório com a seguinte estrutura principal:

```
docker-compose.yml
README.md
src/
  api.py
  Dockerfile
  requirements.txt
  static/index.html
scripts/
  populate_db.py
  load_test_python.py
  benchmark_api.py
  run_final_experiment.py
  run_experiment.sh
experiments/load_test.js
prometheus/prometheus.yml
tests/test_api.py
results/benchmark/
  raw.json
  summary.csv
  table_pagination.tex
  table_versioning.tex
  table_resources.tex
  resource_usage.csv
  latency_chart.svg
requirements-dev.txt
```

A aplicação principal está em `src/api.py`. Na inicialização, a API cria a tabela `produtos` caso ela ainda não exista. Os endpoints implementados são:

- GET `/api/health`: verificação de saúde da API;
- GET `/metrics`: métricas no formato Prometheus;
- GET `/v1/produtos`: V1 com paginação *Offset*;
- GET `/v1/produtos/cursor`: V1 com paginação *Cursor*;
- GET `/v2/produtos`: V2 com paginação *Offset* e campo meta;
- GET `/v2/produtos/cursor`: V2 com paginação *Cursor* e campo meta;
- GET `/produtos`: versionamento por cabeçalho `Accept`.

O script `scripts/populate_db.py` gera registros artificiais com campos `id`, `nome`, `categoria`, `preco`, `estoque`, `criado_em` e `atualizado_em`. O teste de carga principal está em `experiments/load_test.js`, usando K6. Há também uma alternativa em Python assíncrono em `scripts/load_test_python.py`. Para a entrega final, o script `scripts/run_final_experiment.py` automatiza a execução completa: recria a base, inicia a API, monitora CPU/memória, executa o benchmark e grava os artefatos finais.

A execução básica do sistema é:

```
docker compose up -d --build
docker exec ssc0158_api python /app/scripts/populate_db.py
/app/data/products.db 10000
```




Fig. 1. Arquitetura implementada para avaliação experimental da API RESTful.

k6 run -e BASE_URL=http://localhost:8000 exper-Foram avaliados quatro alvos: paginação *Offset* profunda

A reprodução do experimento final usado neste relatório pode ser feita em um comando:

```

./venv/bin/python \
scripts/run_final_experiment.py \
--port 8010 --products 10000 \
--repetitions 5 \
--output-dir results/benchmark

```

VI. CONFIGURAÇÃO EXPERIMENTAL

Os experimentos finais foram executados em 6 de junho de 2026 contra a API FastAPI em `http://127.0.0.1:8010`, com banco SQLite dedicado em `results/benchmark/products.db`. A base foi recriada antes da medição e populada com 10.000 produtos artificiais. A execução foi conduzida pelo script `scripts/run_final_experiment.py`, que inicia a API, monitora CPU/memória do processo e aciona o benchmark `scripts/benchmark_api.py`, baseado em `httpx` assíncrono.

Cada combinação de cenário e alvo foi repetida cinco vezes. Em cada repetição, o script disparou requisições concorrentes e registrou latência, quantidade de requisições, taxa de erro, tempo total e *throughput*. A Tabela II descreve a carga efetivamente utilizada.

TABLE II
CENÁRIOS EXPERIMENTAIS EXECUTADOS

Cenário	Usuários	Req./usuário	Req./repetição
C1 – Baixa	10	8	80
C2 – Média	50	6	300
C3 – Alta	100	4	400

em `/v1/produtos?limit=50&offset=9000`,
paginação *Cursor* profunda em
`/v1/produtos/cursor?limit=50&cursor=9000`,
versionamento via URI em
`/v2/produtos?limit=50&offset=0` e versionamento
via cabeçalho em `/produtos?limit=50&offset=0`
com `Accept: application/vnd.api.v2+json`. No
total, foram executadas 15.600 requisições HTTP, resultantes
de 3 cenários, 4 alvos, 5 repetições e diferentes quantidades
de requisições por repetição.

As métricas agregadas foram calculadas sobre as cinco repetições de cada combinação. O intervalo de confiança de 95% foi calculado sobre a média de latência de cada repetição, usando valor crítico *t* para cinco amostras. O processo da API foi amostrado 662 vezes para CPU e memória residente.

VII. RESULTADOS EXPERIMENTAIS

A Tabela III resume as evidências de implementação e execução. Além dos testes unitários, os resultados brutos e processados foram armazenados em `results/benchmark/`. Os arquivos principais são `raw.json`, com as execuções individuais, `summary.csv`, com os dados agregados, `table_pagination.tex`, `table_versioning.tex`, `table_resources.tex`, `resource_usage.csv` e `latency_chart.svg`.

A. Paginação: *Offset* vs. *Cursor*

A Tabela IV apresenta os resultados da comparação entre paginação *Offset* e *Cursor* em página profunda. A coluna “Média” representa a média da latência média das cinco repetições. A coluna “DP” representa o desvio padrão dessas médias, e “IC95” representa a margem do intervalo de confiança de 95%.

TABLE III
EVIDÊNCIAS EXPERIMENTAIS DO PROTÓTIPO

Evidência	Status
API REST	Endpoints V1, V2, cursor, offset e header implementados.
Banco	SQLite experimental com 10.000 produtos.
Dashboard	Página web consulta os endpoints reais de produtos.
Observabilidade	Endpoint <code>/metrics</code> expõe métricas Prometheus.
Testes unitários	6 testes automatizados executados com sucesso.
Benchmark	15.600 requisições HTTP, 60 execuções agregadas e 0% de erro.
Resultados	JSON, CSV, tabelas LaTeX e SVG gerados em <code>results/benchmark/</code> .

A paginação *Cursor* apresentou menor latência média em C1 e C3, mas não em C2. Em C1, a redução foi de aproximadamente 9,1%; em C3, de 0,8%. Em C2, o *Offset* apresentou latência média cerca de 2,3% menor. Apesar disso, o p95 da estratégia por *Cursor* foi menor nos três cenários, sugerindo melhor comportamento nas requisições mais lentas. Como os intervalos de confiança são próximos e há inversão na média em C2, os resultados apoiam H1 de forma moderada, não conclusiva.

B. Versionamento: URI vs. Cabeçalhos HTTP

A Tabela V apresenta os resultados da comparação entre versionamento via URI e via cabeçalhos HTTP. O objetivo principal dessa comparação é avaliar evolutividade, mas a medição de desempenho verifica se a negociação por cabeçalho introduz impacto perceptível na resposta.

Os resultados de desempenho entre URI e cabeçalhos foram próximos. Em C1, o versionamento por cabeçalho foi ligeiramente mais rápido; em C2, os valores foram praticamente equivalentes; em C3, a URI apresentou menor latência média. Em todos os casos, a taxa de erro foi 0%. Portanto, não houve evidência de custo relevante de desempenho para a negociação por cabeçalho. A avaliação de H2 permanece principalmente arquitetural: o cabeçalho preserva a URI do recurso e reduz o acoplamento entre identificação do recurso e versão da representação, enquanto a URI versionada é mais explícita e simples de observar em logs e testes manuais.

A Figura 2 reforça visualmente o crescimento de latência conforme a carga aumenta. A diferença entre estratégias permanece pequena em relação ao salto entre C1, C2 e C3, indicando que o nível de concorrência teve efeito maior sobre o tempo de resposta do que a escolha de versionamento.

C. Consumo de Recursos

Durante a execução final, o processo da API foi amostrado 662 vezes por meio de `/proc`. A Tabela VI apresenta o uso médio e máximo de CPU e memória residente (RSS). O valor máximo de CPU pode ultrapassar 100% porque representa uso acumulado em múltiplos núcleos lógicos durante intervalos curtos.

VIII. DISCUSSÃO

Os resultados indicam que a paginação por *Cursor* apresentou vantagem em C1 e C3, além de p95 menor nos três cenários, embora a magnitude da diferença tenha sido pequena no ambiente avaliado. Isso é coerente com a expectativa teórica: em consultas profundas, a estratégia por cursor evita a semântica de descarte de registros associada ao *Offset*. Entretanto, como o banco utilizado foi SQLite local, com apenas 10.000 registros e sem rede entre aplicação e banco, a diferença observada tende a ser menor do que em cenários com bancos cliente-servidor, maior cardinalidade ou consultas mais complexas.

No C3, que representa a maior carga aplicada, o *Cursor* reduziu a latência média de 2258,78 ms para 2241,29 ms e elevou o *throughput* médio de 92,47 para 93,47 requisições por segundo. O p95 também foi ligeiramente menor para *Cursor*. Esse comportamento apoia H1 de maneira moderada: a estratégia alternativa apresentou melhor comportamento em parte das métricas, mas não com diferença grande o suficiente para ignorar a sobreposição dos intervalos de confiança e a variabilidade natural do ambiente.

Para versionamento, os resultados mostram que a escolha entre URI e cabeçalho não introduziu impacto relevante de desempenho no protótipo. A diferença deve ser interpretada principalmente em termos de evolução. A URI versionada é mais simples para clientes, documentação e inspeção manual, pois a versão está explícita no caminho. Já o cabeçalho HTTP preserva a estabilidade da URI e permite tratar a versão como uma escolha de representação, o que reduz o acoplamento conceitual entre recurso e versão. Assim, H2 é apoiada do ponto de vista arquitetural, mas não por uma diferença mensurável de latência.

A taxa de erro igual a 0% em todos os cenários indica que a API manteve confiabilidade funcional sob as cargas aplicadas. O consumo médio de CPU foi de 37,77%, com pico de 334,44%, e a memória residente média foi de 72,72 MB, com pico de 103,94 MB. Esses valores indicam que o protótipo executou a carga sem esgotamento de recursos no ambiente usado, mas também mostram que a concorrência eleva rapidamente a latência quando múltiplas requisições simultâneas disputam o mesmo processo e o mesmo arquivo SQLite.

IX. AMEAÇAS À VALIDADE

A. Validade Interna

Os resultados podem ser afetados por estado do cache, concorrência de processos na máquina, escalonamento do sistema operacional, aquecimento da aplicação e características do SQLite. Para mitigar essas ameaças, os cenários foram repetidos cinco vezes e os dados brutos foram preservados em `results/benchmark/raw.json`. Ainda assim, a execução local pode ter sofrido interferências de outros processos.

B. Validade Externa

O domínio de produtos é propositalmente simples. Assim, os resultados podem não generalizar diretamente para APIs com filtros complexos, *joins*, autenticação, autorização, payloads

TABLE IV
RESULTADOS DA COMPARAÇÃO ENTRE PAGINAÇÃO OFFSET E CURSOR

Cenário	Estratégia	Média (ms)	DP	IC95	p95 (ms)	RPS	Erro (%)
C1	Offset	92.56	6.17	7.66	143.82	487.66	0.00
C1	Cursor	84.14	6.57	8.16	133.32	519.71	0.00
C2	Offset	825.19	19.45	24.15	1314.21	199.80	0.00
C2	Cursor	844.58	21.74	26.99	1269.19	195.36	0.00
C3	Offset	2258.78	34.72	43.11	3568.01	92.47	0.00
C3	Cursor	2241.29	41.24	51.20	3559.47	93.47	0.00

TABLE V
RESULTADOS DA COMPARAÇÃO ENTRE VERSIONAMENTO VIA URI E VIA CABEÇALHOS HTTP

Cenário	Estratégia	Média (ms)	DP	IC95	p95 (ms)	RPS	Erro (%)
C1	URI v2	89.48	4.88	6.06	142.22	487.55	0.00
C1	Header v2	87.61	2.89	3.59	137.75	497.58	0.00
C2	URI v2	846.79	40.39	50.15	1219.98	196.07	0.00
C2	Header v2	847.71	18.74	23.26	1188.20	195.66	0.00
C3	URI v2	2252.37	24.91	30.92	3730.96	93.07	0.00
C3	Header v2	2276.64	64.84	80.49	3677.21	92.12	0.00




Fig. 2. Latência média por cenário e estratégia nos experimentos finais.

TABLE VI
CONSUMO DE RECURSOS OBSERVADO DURANTE O EXPERIMENTO FINAL

Componente	Amostras	CPU média (%)	CPU máx. (%)	RSS médio (MB)	RSS máx. (MB)
API	662	37.77	334.44	72.72	103.94

maiores, bancos distribuídos ou múltiplas réplicas. A escolha por SQLite favorece reprodutibilidade, mas limita extrapolação para PostgreSQL, MySQL ou bancos distribuídos.

C. Validade de Construto

Latência, *throughput*, p95 e taxa de erro são métricas adequadas para desempenho e confiabilidade, mas não capturam completamente experiência do desenvolvedor ou facilidade de manutenção. A avaliação de evolutividade combina evidência quantitativa de rotas e estrutura com análise qualitativa dos *trade-offs* entre URI e cabeçalhos.

D. Validade de Conclusão

Como cada combinação foi repetida cinco vezes, o IC95 oferece uma medida inicial de incerteza, mas diferenças pequenas devem ser interpretadas com cautela. A hipótese H1 é apoiada de forma moderada, não absoluta, porque a vantagem do *Cursor* não ocorreu em todas as médias. A hipótese H2 é sustentada principalmente por argumento arquitetural, e não por diferença estatística de desempenho.

X. CHECKLIST DE REPRODUTIBILIDADE

TABLE VII
CHECKLIST DE REPRODUTIBILIDADE

Item	Status	
Docker/Compose	Implementado	em
Dependências fixadas	Implementado	em
README de execução	Implementado no README principal e em relatório/README.md.	e
Script de população	Implementado	em
Script de experimento final	Implementado	em
Script de benchmark/análise	Implementado	em
Observabilidade	Implementada com Prometheus/Grafana e /metrics.	e
Dashboard web	Implementado	em
Resultados brutos	Implementado	em
Gráficos e tabelas	Implementado	em
CPU e memória	Implementado	em
Micro-PRISMA	Resumido neste relatório; planilha externa deve acompanhar a entrega, se exigida pelo docente.	e

XI. CONCLUSÃO

Este relatório consolidou a proposta, a implementação e a avaliação experimental de um estudo sobre decisões de design em APIs RESTful. O protótipo desenvolvido atende ao núcleo técnico do Tema 4 da disciplina: implementa uma

API RESTful containerizada, com estratégias alternativas de paginação e versionamento, banco de dados, dashboard web, testes automatizados, scripts de carga, coleta de métricas e observabilidade com Prometheus/Grafana.

Os experimentos executados totalizaram 15.600 requisições HTTP e não registraram erros. A paginação por *Cursor* apresentou menor latência média em C1 e C3 e menor p95 nos três cenários, apoiando H1 de forma moderada. A comparação entre versionamento via URI e via cabeçalhos HTTP não indicou diferença relevante de desempenho, mas reforçou o *trade-off* arquitetural de H2: URIs versionadas são mais explícitas, enquanto cabeçalhos reduzem o acoplamento entre recurso e versão da representação. O processo da API consumiu, em média, 37,77% de CPU e 72,72 MB de memória RSS durante a execução. Como trabalhos futuros, recomenda-se repetir os testes na VM da disciplina, ampliar o volume de dados e avaliar um banco cliente-servidor, como PostgreSQL, para aumentar a validade externa dos resultados.

APPENDIX A RESUMO DO MICRO-PRISMA

TABLE VIII
RESUMO DO PROCESSO MICRO-PRISMA

Etapas	Qtd.	Descrição
Identificação	45	Registros obtidos com quatro strings em IEEE Xplore, ACM Digital Library, Scopus e buscas complementares.
Triagem	12	Trabalhos selecionados por título e resumo para leitura completa ou parcial.
Inclusão final	8	Estudos diretamente usados na tabela de extração e fundamentação.

Os critérios de inclusão priorizaram estudos empíricos ou metodológicos relacionados a APIs REST, desempenho, evolução, versionamento, boas práticas e observabilidade. Os critérios de exclusão removeram textos opinativos, tutoriais, trabalhos sem relação direta com REST/HTTP e estudos exclusivamente focados em segurança. A lacuna identificada foi a baixa quantidade de estudos que isolam experimentalmente decisões internas de design REST, como paginação e versionamento, em um mesmo ambiente controlado.

APPENDIX B ARTEFATOS DE REPRODUTIBILIDADE

Os principais artefatos para reprodução são: `docker-compose.yml`, `src/Dockerfile`, `src/requirements.txt`, `requirements-dev.txt`, `scripts/populate_db.py`, `scripts/benchmark_api.py`, `scripts/run_final_experiment.py`, `experiments/load_test.js`, `prometheus/prometheus.yml` e o diretório `results/benchmark/`. O comando recomendado para reproduzir a rodada final é:

```
./venv/bin/python \
scripts/run_final_experiment.py \
```

```
--port 8010 --products 10000 \
--repetitions 5 \
--output-dir results/benchmark
```

A geração dos produtos é determinística em função do índice *i*; portanto, não há semente aleatória a controlar. Os metadados de execução ficam registrados em `summary.json` e `resource_usage.json`.

REFERENCES

- [1] R. T. Fielding, “Architectural styles and the design of network-based software architectures,” Ph.D. dissertation, University of California, Irvine, 2000. [Online]. Available: <https://www.ics.uci.edu/~fielding/pubs/dissertation/top.htm>
- [2] M. S. M. Elghazal, A. Aneiba, and E. Q. Shahra, “Performance evaluation of rest and graphql api models in microservices software development domain,” in *Proceedings of the 21st International Conference on Web Information Systems and Technologies (WEBIST 2025)*. SCITEPRESS, 2025.
- [3] S. Gholami, A. Goli, C.-P. Bezemer, and H. Khazaei, “A framework for satisfying the performance requirements of containerized software systems through multi-versioning,” in *Proceedings of the 2020 ACM/SPEC International Conference on Performance Engineering*. ACM, 2020.
- [4] M. Szewczyk and M. Skublewska-Paszkowska, “Performance comparison of development frameworks in selected environments in rest api architecture,” *Journal of Computer Sciences Institute*, vol. 35, pp. 121–128, 2025.
- [5] J. Bogner, R. Verdecchia, and I. Gerostathopoulos, “Restruler: Towards automatically identifying violations of restful design rules in web apis,” in *Proceedings of the 21st IEEE International Conference on Software Architecture (ICSA 2024)*. IEEE, 2024, pp. 123–134.
- [6] T. M. Mabotha, R. Grobbelaar, T. P. Matiea, and P. K. Okuthe, “Performance evaluation of a dynamic restful api using fastapi, docker and nginx,” in *2024 International Conference on Artificial Intelligence, Big Data, Computing and Data Communication Systems (icABCD)*. IEEE, 2024.
- [7] A. Neumann, N. Laranjeiro, and J. Bernardino, “An analysis of public rest web service apis,” *IEEE Transactions on Services Computing*, vol. 14, no. 4, pp. 957–970, 2021.
- [8] M. De Luca, M. Perlotto, A. R. Fasolino, and P. Tramontana, “Architectural anti-patterns in student-developed microservice architectures: An exploratory study,” 2026. [Online]. Available: <https://arxiv.org/abs/2602.07147>
- [9] A. Kandiraju, “Streaming rest apis for large financial transaction exports from relational databases,” 2026. [Online]. Available: <https://arxiv.org/abs/2603.12566>